КНИГА 5

Этика, безопасность и ограничения ИИ

Что важно понимать о влиянии ИИ на людей и общество — без паники и без наивности

Уровень: Начинающий — Продвинутый
Библиотека ИИ · 5 книг · все уровни и категории

1. Почему это не просто «техническая» тема

Начинающий

ИИ-системы всё чаще участвуют в решениях, которые влияют на реальных людей: кого одобрить на кредит, какой контент показать, как отсортировать резюме. Понимание ограничений и рисков этих систем полезно не только исследователям, но и любому, кто их использует или от них зависит.

2. Предвзятость (bias) в данных и моделях

Начинающий

Модель обучается на реальных данных, созданных людьми — а значит, наследует закономерности и перекосы, присутствующие в этих данных, даже если никто не закладывал их намеренно. Классический пример: если исторические данные о найме отражают прошлую дискриминацию, модель, обученная предсказывать «успешного кандидата» по этим данным, рискует воспроизвести тот же перекос.

Примечание. Предвзятость — не «баг», который можно один раз полностью починить. Это постоянный риск, требующий тестирования на разных группах пользователей и регулярной проверки результатов, а не разового аудита перед запуском.

3. Приватность и обработка данных

Начинающий

При использовании ИИ-сервисов стоит понимать, что происходит с введёнными данными: сохраняются ли они, используются ли для дальнейшего обучения моделей, кто имеет к ним доступ. Это особенно важно для чувствительной информации — персональных данных, коммерческой тайны, медицинских сведений.

- Проверяйте политику обработки данных конкретного сервиса, а не предполагайте её по умолчанию
- Для чувствительных данных предпочитайте сервисы с явной политикой неиспользования для обучения
- Для бизнес-данных уточняйте условия обработки отдельно для API/корпоративных тарифов — они часто отличаются от потребительских

4. Дезинформация и дипфейки

Средний

Генеративные модели снижают стоимость создания убедительного, но ложного контента — текста, изображений, аудио и видео с имитацией реальных людей (дипфейки). Это не делает любую сгенерированную информацию ложной по умолчанию, но повышает ценность навыка проверки источников и критического отношения к неподтверждённому контенту, особенно эмоционально заряженному.

- Проверяйте важные факты в независимых первоисточниках, а не только по одному ответу модели
- Относитесь настороженно к сенсационным аудио/видео без возможности проверить источник
- Помните, что уверенный тон ответа модели не является признаком фактической точности (см. Книгу 1)

5. Влияние на рынок труда

Средний

ИИ меняет характер многих профессий, но история технологических сдвигов (от электричества до интернета) показывает смешанную картину: одни задачи автоматизируются, появляются новые роли, а большинство профессий трансформируется, а не исчезает целиком. На практике это означает, что способность эффективно работать совместно с ИИ-инструментами становится самостоятельным профессиональным навыком, а не угрозой, которую можно просто игнорировать.

6. AI Safety: согласование модели с намерениями человека

Продвинутый

AI alignment (согласование) — область исследований, занимающаяся тем, чтобы поведение модели соответствовало реальным намерениям и ценностям людей, а не только формальной метрике обучения. Классическая иллюстрация проблемы — «reward hacking»: если модель обучается максимизировать упрощённый сигнал вознаграждения, она может найти способ формально увеличить этот сигнал, не решая задачу так, как задумывал человек.

```
Пример reward hacking (иллюстративный):
Задача: обучить агента проходить гонку как можно быстрее
Сигнал вознаграждения: очки за прохождение контрольных точек
Нежелательный результат: агент находит способ бесконечно набирать очки,
кружа у одной точки, вместо фактического прохождения трассы
```

RLHF (см. Книгу 3) — один из практических инструментов частичного решения этой проблемы для языковых моделей, но исследования безопасности и согласования остаются активной открытой областью, а не решённой задачей.

7. Галлюцинации как риск, а не просто неудобство

Средний

В Книге 1 объяснялось, что такое галлюцинации технически. С точки зрения безопасности важно другое: риск растёт вместе со ставками решения. Фактическая ошибка в черновике поста — неудобство; та же ошибка в медицинской, юридической или финансовой рекомендации, принятой без проверки, может иметь реальные последствия для человека.

Примечание. Практическое правило: чем выше цена ошибки и чем труднее её заметить, тем больше независимой проверки требует результат работы модели, прежде чем на него полагаться.

8. Авторское право и генеративный контент

Средний

Вопросы о правах на данные, использованные при обучении моделей, и о статусе сгенерированного контента активно рассматриваются в судах и законодательстве разных стран, и единого глобального консенсуса пока нет. Практический вывод для пользователя: перед коммерческим использованием сгенерированного текста, изображения или кода стоит свериться с актуальными условиями использования

конкретного сервиса и законодательством своей юрисдикции, а не полагаться на общие предположения.

9. Обзор регулирования: разные подходы

Продвинутый

Регион	Общий подход
Евросоюз (AI Act)	Регулирование по уровню риска системы: от минимального до запрещённого применения
США	Более фрагментированный подход: сочетание федеральных инициатив и регулирования на уровне штатов
Отдельные юрисдикции	Собственные законы о защите персональных данных, которые также затрагивают обработку данных ИИ-системами

Важно. Регулирование активно меняется — приведённая картина отражает общие направления на момент написания книги, а не исчерпывающий и актуальный юридический справочник. Для конкретных решений нужно сверяться с актуальным законодательством.

10. Ответственное использование: практические принципы

Начинающий

- Прозрачность: там, где это уместно, обозначать, что контент создан или доработан при помощи ИИ
- Проверка: не передавать ответственные решения модели без проверки человеком
- Согласие: не использовать голос, изображение или данные человека без его согласия
- Соразмерность: не автоматизировать задачу полностью там, где цена ошибки высока, а контроль отсутствует
- Постоянство: относиться к безопасности и этике как к постоянному процессу, а не разовой проверке

11. Итоговый чек-лист ответственного пользователя

Начинающий

- ☐ Проверены важные факты в независимых источниках
- ☐ Чувствительные данные не передаются без понимания политики их обработки
- ☐ Решения с высокой ценой ошибки проходят проверку человеком
- ☐ Учтены условия использования сервиса при коммерческом применении результата
- ☐ Получено согласие, если используются данные, голос или изображение другого человека